

Untitled

2024-12-26

#Participants Àlex Soler Carballo
Les dades seran extretes de dades_64.txt

Llibreríes

```
library(FactoMineR)
library(car)
```

```
## Cargando paquete requerido: carData
```

```
library(lmtest)
```

```
## Cargando paquete requerido: zoo
```

```
##
## Adjuntando el paquete: 'zoo'
```

```
## The following objects are masked from 'package:base':
##
##      as.Date, as.Date.numeric
```

```
library(effects)
```

```
## lattice theme set by effectsTheme()
## See ?effectsTheme for details.
```

```
library(ROCR)
library(AUC)
```

```
## AUC 0.3.2
```

```
## Type AUCNews() to see the change log and ?AUC to get an overview.
```

```
library(caret)
```

```
## Cargando paquete requerido: ggplot2
```

```
## Warning: package 'ggplot2' was built under R version 4.4.3
```

```
## Cargando paquete requerido: lattice
```

```
##
```

```
## Adjuntando el paquete: 'caret'
```

```
## The following objects are masked from 'package:AUC':
```

```
##
```

```
##      sensitivity, specificity
```

```
library(ggplot2)
```

Lectura de dades

```
dades<-read.table("dades_64.txt",header=T)
summary(dades)
```

```
##      ID          sexe      visites_prev      FEV
## Min.   : 1.0    Length:500    Length:500    Min.   : 50
## 1st Qu.:125.8    Class :character    Class :character    1st Qu.: 82
## Median :250.5    Mode  :character    Mode  :character    Median :101
## Mean   :250.5
## 3rd Qu.:375.2
## Max.   :500.0
##      edat          PAS          temps          n
## Min.   : 18.00    Min.   : 73.0    Min.   : 366.0    Min.   : 0.00
## 1st Qu.: 35.00    1st Qu.:110.0    1st Qu.: 765.5    1st Qu.: 0.00
## Median : 49.00    Median :121.0    Median :1117.0    Median : 0.00
## Mean   : 50.17    Mean   :120.2    Mean   :1107.3    Mean   : 1.16
## 3rd Qu.: 64.00    3rd Qu.:130.2    3rd Qu.:1427.0    3rd Qu.: 1.00
## Max.   :105.00    Max.   :166.0    Max.   :1816.0    Max.   :35.00
##      y
## Min.   :0.000
## 1st Qu.:0.000
## Median :0.000
## Mean   :0.342
## 3rd Qu.:1.000
## Max.   :1.000
```

Preprocessament de les dades

```
#Passem a factor
dades$sexe<-as.factor(dades$sexe)

dades$visites_prev<-as.factor(dades$visites_prev)
```


```
#Variable resposta com a factor
dades$visita<-factor(dades$y,labels=c("No_visita","Si_visita"))

#Variable auxiliar per si agruem dades
#dades$ones<-rep(1,length(dades$y))
dades$ID<-NULL
```

Part inicial


Catègriques: sexe,visites_prev Numèriques: FEV,edat,PAS,temps Resposta:y/visita,n ### 1. Descriptiva
a.Univariada

```
par(mfrow=c(1,3),las=2)
barplot(table(dades$sexe),col=c(2,3))
barplot(table(dades$visites_prev),col=c(2,3))
barplot(table(dades$visita),col=c(2,3))
```



Sembla que dades visites_prev estan desbalancejades, repartides entre 20% no 80% si. Pero a lo millor segueix sent útil (serie inútil si el 90% o mes fossin d'una categoria). La variable resposta i l'altre categòrica si que estan balancejades

```
par(mfrow=c(1,3),las=2)
hist(dades$FEV)
hist(dades$edat)
hist(dades$PAS)
```




```


par(mfrow=c(1,2), las=2)
hist(dades$temps)
hist(dades$n)

```

Histogram of dades\$temps



Histogram of dades\$n



Podem observar com la variable resposta de recomptes té molts 0 (possible poisson zero inflada)

```
shapiro.test(dades$PAS)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  dades$PAS
## W = 0.99594, p-value = 0.2263
```

b. Bivariada

```
response <- which(names(dades[,c(-7,-8)])=='visita')
catdes(dades[,c(-7,-8)],num.var=response)
```

Var resposta y/visita

```
##
## Link between the cluster variable and the categorical variables (chi-square test)
## =====
##           p.value df
## sexe 5.229737e-05  1
##
```



```
## Description of each cluster by the categories
## =====
## $No_visita
##          Cla/Mod  Mod/Cla Global      p.value    v.test
## sexe=dona 74.59016 55.31915   48.8 5.205886e-05  4.046186
## sexe=home 57.42188 44.68085   51.2 5.205886e-05 -4.046186
##
## $Si_visita
##          Cla/Mod  Mod/Cla Global      p.value    v.test
## sexe=home 42.57812 63.74269   51.2 5.205886e-05  4.046186
## sexe=dona 25.40984 36.25731   48.8 5.205886e-05 -4.046186
##
##
## Link between the cluster variable and the quantitative variables
## =====
##          Eta2      P-value
## FEV    0.208333979 4.240784e-27
## temps 0.009136264 3.260905e-02
##
## Description of each cluster by quantitative variables
## =====
## $No_visita
##          v.test Mean in category Overall mean sd in category Overall sd
## temps  -2.135181      1079.4894      1107.280      404.30676  403.28688
## FEV    -10.196012      91.8541      100.956      25.84881   27.65997
##          p.value
## temps 3.274627e-02
## FEV   2.065822e-24
##
## $Si_visita
##          v.test Mean in category Overall mean sd in category Overall sd
## FEV    10.196012      118.4678      100.956      22.03354   27.65997
## temps  2.135181      1160.7485      1107.280      395.86716  403.28688
##          p.value
## FEV    2.065822e-24
## temps 3.274627e-02
```

Podem observar com les variables que tenen relació amb la variable resposta visita/y son: Sexe, temps, FEV

```
par(mfrow=c(1,2),las=1)
Boxplot(FEV~visita, data = dades, col=2:3)
```

```
## [1] "353"
```



```
Boxplot(temps~visita,data = dades, col=2:3)
```



```
par(mfrow=c(1,2),las=1)
Boxplot(PAS~visita,data = dades, col=2:3)
```

```
## [1] "284" "238"
```


```
Boxplot(edat~visita,data = dades, col=2:3)
```



```
## [1] "363"
```



Veiem gràficament com si tenim diferències segons nivell resposta per FEV i temps però en les altres dues veiem que els boxplots son pràcticament iguals (indicant que aquestes dues pot ser no serveixen de molt per explicar visita/y)

```
par(mfrow=c(1,2),las=1)
plot(visita~sexe, data = dades, col=3:2)
plot(visita~visites_prev, data = dades, col=3:2)
```





Aquí veiem el mateix que en tests, sexe si que te diferents proporcions en canvi visites_prev son semblants.

```
par(mfrow=c(1,2))
plot(dades$sexe,col=c(2,3),ylim=c(0,5))
plot(dades$visites_prev,col=c(2,3),ylim=c(0,5))
```




Var resposta n recomptes

```
par(mfrow=c(1,2))
plot(dades$n~dades$FEV)
plot(dades$n~dades$edat)
```



```
par(mfrow=c(1,2))
plot(dades$n~dades$PAS)
plot(dades$n~dades$temps)
```



Resposta binaria

Ajustar model amb funcio logit

Posem totes les vars de forma aditiva i totes possibles interaccions ordre 1 amb al menys una variable categòrica

```
mod0 <- glm(visita ~ sexe+visites_prev+FEV+edat+PAS+temps+
  sexe:visites_prev+sexe:FEV+sexe:edat+sexe:PAS+sexe:temps+
  visites_prev:FEV+visites_prev:edat+visites_prev:PAS+visites_prev:temps,
  family = binomial(link = "logit"), data=dades)

# Fem selecció automàtica per tenir una orientació
mod0.1 <- step(mod0,direction="both",k=2,trace=FALSE) #Segons AIC on es busca predictibilitat
mod0.2 <- step(mod0,direction="both",k=log(nrow(dades)),trace=FALSE) #segons BIC on es busca explicabil
Anova(mod0.1)
```

```
## Analysis of Deviance Table (Type II tests)
##
## Response: visita
##          LR Chisq Df Pr(>Chisq)
## sexe          27.333  1  1.713e-07 ***
## visites_prev    3.314  1  0.068707 .
## FEV           130.890  1  < 2.2e-16 ***
```


```
## edat          2.339  1  0.126171
## PAS           0.898  1  0.343223
## temps         7.303  1  0.006884 **
## sexe:FEV       6.163  1  0.013043 *
## sexe:edat      2.161  1  0.141551
## sexe:PAS       3.516  1  0.060796 .
## visites_prev:FEV 2.397  1  0.121552
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Anova(mod0.2)
```


```
## Analysis of Deviance Table (Type II tests)
##
## Response: visita
##      LR Chisq Df Pr(>Chisq)
## sexe    29.338  1 6.078e-08 ***
## FEV    130.410  1 < 2.2e-16 ***
## temps    7.508  1  0.006144 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Pel primer model al utilitzar criteri AIC ens surten coeficients no significatius i amb BIC veiem que ens surten moltes menys variables i totes significatives. El que farem nosaltres serà fer una selecció manual per trobar un model que estigui entre aquests dos ja que busquem explicabilitat i predictibilitat.

```
residualPlot(mod0.1,ylim=c(-2,2))
```



```
residualPlot(mod0.2,ylim=c(-2,2))
```







FEV

```
m1<-glm(visita ~ FEV,
        family = binomial(link = "logit"), data=dades)
Anova(m1)

## Analysis of Deviance Table (Type II tests)
##
## Response: visita
##      LR Chisq Df Pr(>Chisq)
## FEV    114.66  1  < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1



par(mfrow=c(1,2))
plot(m1)[c(3,4)]
```





```
## NULL
```


```
residualPlots(m1)
```




```
##      Test stat Pr(>|Test stat|)
## FEV    3.6408      0.05638 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
marginalModelPlots(m1)
```

Marginal Model Plots



```
plot(allEffects(m1),ask=FALSE)
```



Veiem que no acaba d'ajustar-se bé a les dades. També podem veure com hi han possibles outliers

```
dades$FEV2<-(dades$FEV-100)^2
dades$FEV3<-(dades$FEV-100)^3

m1.2<-glm(visita ~ FEV+FEV2,
           family = binomial(link = "logit"), data=dades)
m1.3<-glm(visita ~ FEV+FEV2+FEV3,
           family = binomial(link = "logit"), data=dades)

m1.2p<-glm(visita ~ poly(FEV,2),
            family = binomial(link = "logit"), data=dades)
m1.3p<-glm(visita ~ poly(FEV,3),
            family = binomial(link = "logit"), data=dades)
anova(m1.3p,m1.2p,test="Chisq")
```

Poly 2n grau i 3r grau

```
## Analysis of Deviance Table
##
## Model 1: visita ~ poly(FEV, 3)
## Model 2: visita ~ poly(FEV, 2)
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1      496      522.14
```

```
## 2      497      524.05 -1  -1.9104  0.1669
```

```
anova(m1,m1.2,test="Chisq")
```

```
## Analysis of Deviance Table
##
## Model 1: visita ~ FEV
## Model 2: visita ~ FEV + FEV2
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1      498      527.70
## 2      497      524.05  1   3.6408  0.05638 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
waldtest(m1,m1.2,test="Chisq")
```

```
## Wald test
##
## Model 1: visita ~ FEV
## Model 2: visita ~ FEV + FEV2
##   Res.Df Df Chisq Pr(>Chisq)
## 1      498
## 2      497  1 3.341   0.06758 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
AIC(m1.2p,m1)
```

```
##      df      AIC
## m1.2p  3 530.0545
## m1      2 531.6954
```

```
BIC(m1.2p,m1)
```

```
##      df      BIC
## m1.2p  3 542.6984
## m1      2 540.1246
```


```
anova(m1,m1.2p,test="Chisq")
```

```
## Analysis of Deviance Table
##
## Model 1: visita ~ FEV
## Model 2: visita ~ poly(FEV, 2)
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1      498      527.70
## 2      497      524.05  1   3.6408  0.05638 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```



```
waldtest(m1,m1.2,test="Chisq")
```

```
## Wald test
##
## Model 1: visita ~ FEV
## Model 2: visita ~ FEV + FEV2
##   Res.Df Df Chisq Pr(>Chisq)
## 1     498
## 2     497  1 3.341   0.06758 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
residualPlot(m1.2,ylim=c(-1,2))
```



```
residualPlots(m1)
```



```
##      Test stat Pr(>|Test stat|)
## FEV      3.6408      0.05638 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Terme cúbic no necessari. Després veiem que el terme quadràtic surt no significatiu per poc, llavors ens fixem en AIC i BIC on veiem que BIC és més o menys semblants (una mica pitjor amb terme quadràtic) però com el nostre criteri principal és l'AIC, llavors ens quedarem amb el terme quadràtic.

Intentem introudirla com a factor La passarem com a factor tenint en compte que entre 80-120 es normal, <80 baixa, >120 alta

```
dades$c.FEV <- cut(dades$FEV,breaks=c(49,79,120,151),labels=c("<80","80-120",">120"))
m1.c <- glm(visita~c.FEV,data=dades,family=binomial)
m2.c <- glm(visita ~ c.FEV + poly(FEV,2),data=dades,family=binomial)
anova(m1.c,m2.c,test="Chisq")
```

```
## Analysis of Deviance Table
##
## Model 1: visita ~ c.FEV
## Model 2: visita ~ c.FEV + poly(FEV, 2)
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1      497      553.10
## 2      495      518.91  2    34.187 3.771e-08 ***
```

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
anova(m1.2p,m2.c,test="Chisq")
```

```
## Analysis of Deviance Table
##
## Model 1: visita ~ poly(FEV, 2)
## Model 2: visita ~ c.FEV + poly(FEV, 2)
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1         497      524.05
## 2         495      518.91  2   5.1419  0.07646 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
AIC(m1.c)
```

```
## [1] 559.0994
```

```
AIC(m1.2p)
```

```
## [1] 530.0545
```

```
m2.c <- glm(visita ~ c.FEV + FEV,data=dades,family=binomial)
anova(m1.c,m2.c,test="Chisq")
```

```
## Analysis of Deviance Table
##
## Model 1: visita ~ c.FEV
## Model 2: visita ~ c.FEV + FEV
##   Resid. Df Resid. Dev Df Deviance  Pr(>Chi)
## 1         497      553.1
## 2         496      526.9  1   26.203 3.073e-07 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
anova(m1,m2.c,test="Chisq")
```

```
## Analysis of Deviance Table
##
## Model 1: visita ~ FEV
## Model 2: visita ~ c.FEV + FEV
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1         498      527.7
## 2         496      526.9  2   0.79896  0.6707
```


```
AIC(m1.c)
```

```
## [1] 559.0994
```

```
AIC(m1)
```

```
## [1] 531.6954
```

```
residualPlots(m1.c)
```



Amb anova estem veient que es millor afegir terme quadràtic a categoritzar ja que ens diu que al afegir terme quadràtic millora model i a l'inversa no. També ho comparem amb FEV normal i es millor el FEV sense tocar

Al final deixem la variable FEV amb terme quadràtic

Temps

```
m2.1<-glm(visita ~ poly(FEV,2)+temps,  
          family = binomial(link = "logit"), data=dades)  
#Comprovem linealitat de temps  
m2.2<-glm(visita ~ poly(FEV,2)+poly(temps,2),  
          family = binomial(link = "logit"), data=dades)  
m2.3<-glm(visita ~ poly(FEV,2)+poly(temps,3),  
          family = binomial(link = "logit"), data=dades)  
anova(m2.1,m2.2,test="Chisq")
```

```
## Analysis of Deviance Table
```

```
##
## Model 1: visita ~ poly(FEV, 2) + temps
## Model 2: visita ~ poly(FEV, 2) + poly(temps, 2)
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1      496      515.56
## 2      495      513.96  1   1.5954   0.2066
```

```
anova(m2.3,m2.2,test="Chisq")
```


```
## Analysis of Deviance Table
##
## Model 1: visita ~ poly(FEV, 2) + poly(temps, 3)
## Model 2: visita ~ poly(FEV, 2) + poly(temps, 2)
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1      494      513.25
## 2      495      513.96 -1 -0.71612   0.3974
```

```
Anova(m2.1)
```




```
## Analysis of Deviance Table (Type II tests)
##
## Response: visita
##               LR Chisq Df Pr(>Chisq)
## poly(FEV, 2) 122.214  2  < 2.2e-16 ***
## temps        8.497  1   0.003558 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

No es necessari ni terme cúbic ni quadràtic. Ens quedem amb temps de forma aditiva. Tampoc posem interacció *Mirem ajust del model*

```
residualPlot(m2.1)
```



```
residualPlots(m2.1) #BO PER MIRAR QUE FA FALLAR AL MODEL
```




```
##           Test stat Pr(>|Test stat|)
## poly(FEV, 2)
## temps           1.5954           0.2066
```

```
marginalModelPlots(m2.1)
```

```
## Warning in mmpls(...): Splines and/or polynomials replaced by a fitted linear
## combination
```

Marginal Model Plots



```
AIC(m1.2p)
```

```
## [1] 530.0545
```

```
AIC(m2.1)
```

```
## [1] 523.558
```

```
BIC(m1.2p)
```

```
## [1] 542.6984
```

```
BIC(m2.1)
```

```
## [1] 540.4164
```

Podem veure com residuos no del tot explicats. La variable temps no la modificarem perquè si que explica bé els residuos. En Marginal model plot veiem com el model ajusta bastante bé les dades. Pero intentarem afegir més variables per intentar millorar els residuos

Edat

```
m3.1<-glm(visita ~ poly(FEV,2)+temps+edat,
          family = binomial(link = "logit"), data=dades)
anova(m3.1,m2.1,test="Chisq") #terme edat rebutjat per poc
```

```
## Analysis of Deviance Table
##
## Model 1: visita ~ poly(FEV, 2) + temps + edat
## Model 2: visita ~ poly(FEV, 2) + temps
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1         495      512.11
## 2         496      515.56 -1   -3.4522  0.06317 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
AIC(m3.1,m2.1)
```

```
##      df      AIC
## m3.1  5 522.1058
## m2.1  4 523.5580
```

```
BIC(m3.1,m2.1)
```

```
##      df      BIC
## m3.1  5 543.1788
## m2.1  4 540.4164
```

```
m3.2<-glm(visita ~ poly(FEV,2)+temps+poly(edat,2),
          family = binomial(link = "logit"), data=dades)
anova(m3.2,m2.1,test="Chisq") #tampoc al quadrat
```

```
## Analysis of Deviance Table
##
## Model 1: visita ~ poly(FEV, 2) + temps + poly(edat, 2)
## Model 2: visita ~ poly(FEV, 2) + temps
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1         494      512.09
## 2         496      515.56 -2   -3.4699  0.1764
```

```
dades$c.edat <- cut(dades$edat,breaks=c(-Inf,30,60,Inf),labels=c("<30","30-60",>60"))
m3.c<-glm(visita ~ poly(FEV,2)+temps+c.edat,
          family = binomial(link = "logit"), data=dades)
anova(m3.c,m2.1,test="Chisq")
```


Categoritzar edat

```
## Analysis of Deviance Table
##
```

```
## Model 1: visita ~ poly(FEV, 2) + temps + c.edat
## Model 2: visita ~ poly(FEV, 2) + temps
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1      494      510.83
## 2      496      515.56 -2      -4.73  0.09395 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Edat categoritzada és pitjor. Veiem que edat es rebutjada per poc, així que mirem criteri AIC i veiem com si millora una mica. Inclourem la variable edat

```
residualPlot(m3.1,ylim=c(-2,2))
```



PAS

```
m4.1<-glm(visita ~ poly(FEV,2)+temps+PAS+edat,
           family = binomial(link = "logit"), data=dades)
#anova(m4.1,m2.1,test="Chisq")
anova(m4.1,m3.1,test="Chisq")
```

```
## Analysis of Deviance Table
##
## Model 1: visita ~ poly(FEV, 2) + temps + PAS + edat
```

```
## Model 2: visita ~ poly(FEV, 2) + temps + edat
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1      494      510.39
## 2      495      512.11 -1   -1.7173    0.19
```

Es no significativa per molt. Era de esperar ja que en els boxplots ja hem vist com tenien distribucions semblants pels diferents nivells de visita

Passem a les *categòriques*. Ja hem afegit totes les numèriques útils


Sexe

```
m5.1<-glm(visita ~ poly(FEV,2)+edat+temps+sexe,
          family = binomial(link = "logit"), data=dades)
#anova(m5.1,m2.1,test="Chisq")
anova(m5.1,m3.1,test="Chisq")
```


```
## Analysis of Deviance Table
##
## Model 1: visita ~ poly(FEV, 2) + edat + temps + sexe
## Model 2: visita ~ poly(FEV, 2) + temps + edat
##   Resid. Df Resid. Dev Df Deviance  Pr(>Chi)
## 1      494      484.05
## 2      495      512.11 -1   -28.058 1.178e-07 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Molt significativa, intentem validar el model

```
residualPlot(m5.1)
```



```
residualPlots(m5.1) #BO PER MIRAR QUE FA FALLAR AL MODEL
```




```
##           Test stat Pr(>|Test stat|)
## poly(FEV, 2)
## edat      0.0253      0.8736
## temps     1.0276      0.3107
## sexe
```

```
marginalModelPlots(m5.1)
```

```
## Warning in mmpls(...): Splines and/or polynomials replaced by a fitted linear
## combination
```

Marginal Model Plots



```
## Warning in mmps(...): Interactions and/or factors skipped
```

Els residuos no es podem validar del tot encara que hi ha hagut petita millora. Veiem ara que les dades estan millor ajustades. Es possible que la part que fa que el model no s'acabi de validar sigui FEV on encara tenim una lleugera pendent en els residuos. Intentem introduir interaccions (encara que provem totes le que fa sentit es la de sexe amb FEV)

```
m5.2<-glm(visita ~ FEV*sexe+FEV2+temps+edat,
           family = binomial(link = "logit"), data=dades)
m5.3<-glm(visita ~ FEV2+FEV+sexe*edat+temps,
           family = binomial(link = "logit"), data=dades)
m5.4<-glm(visita ~ poly(FEV,2)*sexe+temps+edat,
           family = binomial(link = "logit"), data=dades)
anova(m5.1,m5.3,test="Chisq")
```

```
## Analysis of Deviance Table
```

```
##
```

```
## Model 1: visita ~ poly(FEV, 2) + edat + temps + sexe
```

```
## Model 2: visita ~ FEV2 + FEV + sexe * edat + temps
```

```
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
```

```
## 1      494      484.05
```

```
## 2      493      481.82  1    2.2241  0.1359
```

```
anova(m5.1,m5.2,test="Chisq")
```

```
## Analysis of Deviance Table
##
## Model 1: visita ~ poly(FEV, 2) + edat + temps + sexe
## Model 2: visita ~ FEV * sexe + FEV2 + temps + edat
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1         494      484.05
## 2         493      480.50  1   3.5526  0.05945 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
anova(m5.2,m5.4,test="Chisq")
```

```
## Analysis of Deviance Table
##
## Model 1: visita ~ FEV * sexe + FEV2 + temps + edat
## Model 2: visita ~ poly(FEV, 2) * sexe + temps + edat
##   Resid. Df Resid. Dev Df   Deviance Pr(>Chi)
## 1         493      480.50
## 2         492      480.49  1 0.00088019  0.9763
```

```
BIC(m5.2,m5.1)
```


```
##      df      BIC
## m5.2  7 523.9979
## m5.1  6 521.3358
```

```
AIC(m5.2,m5.1)
```


```
##      df      AIC
## m5.2  7 494.4956
## m5.1  6 496.0482
```

Descartem interacció sexe temps i sexe amb poly(FEV,2) pero veiem que sexe:FEV surt no significatiu per poc. Mirant AIC veiem que millora respecte el model anterior sense que empitjori molt BIC. Així que com criteri principal AIC afegim interacció.


```
residualPlot(m5.2,ylim=c(-2,2),xlim=c(-4.5,3))
```



```
residualPlot(m5.1,ylim=c(-2,2),xlim=c(-4.5,3))
```



```
residualPlots(m5.2) #BO PER MIRAR QUE FA FALLAR AL MODEL
```




```
##      Test stat Pr(>|Test stat|)
## FEV      0.0000      1.0000
## sexe
## FEV2      2.2842      0.1307
## temps      1.0216      0.3121
## edat      0.0236      0.8779
```

```
marginalModelPlots(m5.2)
```

```
## Warning in mmps(...): Interactions and/or factors skipped
```

Marginal Model Plots



Introduïm interacció encara que no podem acabar de validar. Com hem afegit interacció mirem si ara es necessari el terme quadràtic.

```
m5.2<-glm(visita ~ FEV*sexe+FEV2+temps+edat,
           family = binomial(link = "logit"), data=dades)
m5.5<-glm(visita ~ FEV*sexe+temps+edat,
           family = binomial(link = "logit"), data=dades)
anova(m5.2,m5.5,test="Chisq")
```

```
## Analysis of Deviance Table
##
## Model 1: visita ~ FEV * sexe + FEV2 + temps + edat
## Model 2: visita ~ FEV * sexe + temps + edat
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1      493      480.50
## 2      494      482.83 -1    -2.3354   0.1265
```

```
Anova(m5.5)
```


```
## Analysis of Deviance Table (Type II tests)
##
## Response: visita
##           LR Chisq Df Pr(>Chisq)
## FEV       129.636  1 < 2.2e-16 ***
## sexe       28.393  1 9.903e-08 ***
```

```
## temps      8.041  1  0.004573 **
## edat       2.344  1  0.125764
## FEV:sexe   5.904  1  0.015106 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```





```
m5.6<-glm(visita ~ FEV*sexe+temps,
          family = binomial(link = "logit"), data=dades)
m5<-m5.6
```

Surten que els models son equivalents. Es rebutja la significació de FEV2 per bastant. Treiem terme quadràtic.

```
residualPlot(m5,ylim=c(-2,2))
```




```
residualPlots(m5) #BO PER MIRAR QUE FA FALLAR AL MODEL
```



```
##      Test stat Pr(>|Test stat|)
## FEV      2.0174      0.1555
## sexe
## temps    0.9723      0.3241
```

```
marginalModelPlot(m5)
```



Anova(m5)

```
## Analysis of Deviance Table (Type II tests)
##
## Response: visita
##          LR Chisq Df Pr(>Chisq)
## FEV       130.410  1 < 2.2e-16 ***
## sexe       29.338  1 6.078e-08 ***
## temps       7.746  1 0.005384 **
## FEV:sexe    5.623  1 0.017728 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Provem a introduir última variable



visites_prev

```
m6.1<-glm(visita ~ FEV*sexe+temps+visites_prev,
           family = binomial(link = "logit"), data=dades)
anova(m6.1,m5,test="Chisq")
```

```
## Analysis of Deviance Table
##
```

```
## Model 1: visita ~ FEV * sexe + temps + visites_prev
## Model 2: visita ~ FEV * sexe + temps
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1      494      481.65
## 2      495      485.18 -1   -3.5241  0.06048 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
par(mfrow=c(1,2))
residualPlot(m6.1)
residualPlot(m5)
```



```
AIC(m6.1,m5)
```

```
##      df      AIC
## m6.1  6 493.6509
## m5    5 495.1751
```

```
BIC(m6.1,m5)
```

```
##      df      BIC
## m6.1  6 518.9386
## m5    5 516.2481
```

Surt no significatiu per poc. Mirem AIC i veiem que millora una mica, també tenim en compte BIC que encara que sigui pitjor no el fa baixar molt. Introduïm variable mirarem d'introduir alguna interacció

```
m6.2<-glm(visita ~ FEV*sexe+FEV:visites_prev+visites_prev+temps,
          family = binomial(link = "logit"), data=dades)
m6.3<-glm(visita ~ FEV*sexe+sexe:visites_prev+visites_prev+temps,
          family = binomial(link = "logit"), data=dades)
anova(m6.1,m6.2,test="Chisq")
```

```
## Analysis of Deviance Table
##
## Model 1: visita ~ FEV * sexe + temps + visites_prev
## Model 2: visita ~ FEV * sexe + FEV:visites_prev + visites_prev + temps
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1         494       481.65
## 2         493       479.60  1    2.0472   0.1525
```


```
anova(m6.3,m6.1,test="Chisq")
```

```
## Analysis of Deviance Table
##
## Model 1: visita ~ FEV * sexe + sexe:visites_prev + visites_prev + temps
## Model 2: visita ~ FEV * sexe + temps + visites_prev
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1         493       479.09
## 2         494       481.65 -1    -2.559   0.1097
```

Surten no significatives per molt. No introduïrem interacció. (Tenint en compte que només mirem interaccions de 1er ordre)


```
m7<-m6.1
marginalModelPlots(m7) #veiem com model no ajusta perfectament les dades
```

Marginal Model Plots




```
plot(allEffects(m7))
```


temps effect plot




visites_prev effect plot



FEV*sexe effect plot



```
residualPlot(m7)
```



5. Comparació links

```
mf<-glm(visita ~ FEV*sexe+temps+visites_prev,
        family = binomial(link = "logit"), data=dades)
mf.prob<-glm(visita ~ FEV*sexe+temps+visites_prev,
             family = binomial(link = "probit"), data=dades)
mf.cll<-glm(visita ~ FEV*sexe+temps+visites_prev,
            family = binomial(link = "cloglog"), data=dades)
```

```
df<-data.frame(BIC=c(BIC(mf),BIC(mf.prob),BIC(mf.cll)),AIC=c(AIC(mf),AIC(mf.prob),AIC(mf.cll)),row.names=
df
```

```
##           BIC      AIC
## Logit    518.9386 493.6509
## Probit   518.4713 493.1837
## Cloglog  526.6575 501.3699
```

```
Anova(mf)
```

```
## Analysis of Deviance Table (Type II tests)
##
## Response: visita
```

```
##          LR Chisq Df Pr(>Chisq)
## FEV      132.428  1 < 2.2e-16 ***
## sexe     28.462  1  9.556e-08 ***
## temps    8.636   1  0.003295 **
## visites_prev 3.524  1  0.060481 .
## FEV:sexe  5.231  1  0.022185 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Veiem que el cloglog es el pitjor per qualsevol dels criteris. I probit i logit son molt semblants. Com no millora ningú dels dos ni en 1 unitat, ens quedarem amb funció Logit perquè es més interpretable i es el link per defecte.

6. Validació model

#Funció per calcular pseudo-R2

```
R2<-function(x){
  res<-c()
  for(i in 1:length(x)){
    res<-c(res,100*(1-x[[i]]$dev/x[[i]]$null.dev))
  }
  return(res)
}
```

```
df<-data.frame(AIC=c(AIC(mod0.1,mod0.2,mod0,m1,m1.2,m1.2p,m1.3,m1.3p,m1.c,m2.1,m2.2,m2.3,m2.c,m3.1,m3.2),
df$BIC.df<-c("mod0.1","mod0.2","mod0","m1","m1.2","m1.2p","m1.3","m1.3p","m1.c","m2.1","m2.2","m2.3","m1.2p",
colnames(df)<-c("num.params","AIC","model","BIC","Dev","PseudoR2")
df[order(df$AIC),c(1,3,2,4,5,6)]
```


##	num.params	model	AIC	BIC	Dev	PseudoR2
## 1	11	mod0.1	492.7160	539.0766	470.7160	26.72007
## 26	7	m6.3	493.0919	522.5942	479.0919	25.41612
## 28	6	mf.prob	493.1837	518.4713	481.1837	25.09048
## 25	7	m6.2	493.6038	523.1060	479.6038	25.33644
## 27	6	mf	493.6509	518.9386	481.6509	25.01774
## 20	7	m5.2	494.4956	523.9979	480.4956	25.19760
## 23	6	m5.5	494.8310	520.1187	482.8310	24.83402
## 18	5	m5	495.1751	516.2481	485.1751	24.46911
## 24	5	m5.6	495.1751	516.2481	485.1751	24.46911
## 21	7	m5.3	495.8240	525.3263	481.8240	24.99079
## 19	6	m5.1	496.0482	521.3358	484.0482	24.64454
## 22	8	m5.4	496.4947	530.2116	480.4947	25.19773
## 2	4	mod0.2	498.7979	515.6563	490.7979	23.59377
## 3	16	mod0	499.1032	566.5369	467.1032	27.28250
## 29	6	mf.c11	501.3699	526.6575	489.3699	23.81607
## 14	5	m3.1	522.1058	543.1788	512.1058	20.27660
## 17	6	m4.1	522.3885	547.6762	510.3885	20.54394
## 16	6	m3.c	522.8280	548.1156	510.8280	20.47553

```
## 10      4    m2.1 523.5580 540.4164 515.5580 19.73917
## 11      5    m2.2 523.9626 545.0356 513.9626 19.98754
## 15      6    m3.2 524.0881 549.3757 512.0881 20.27936
## 12      6    m2.3 525.2464 550.5341 513.2464 20.09903
## 5       3    m1.2 530.0545 542.6984 524.0545 18.41645
## 6       3    m1.2p 530.0545 542.6984 524.0545 18.41645
## 7       4    m1.3 530.1441 547.0026 522.1441 18.71386
## 8       4    m1.3p 530.1441 547.0026 522.1441 18.71386
## 4       2      m1 531.6954 540.1246 527.6954 17.84965
## 13      4    m2.c 534.8964 551.7548 526.8964 17.97403
## 9       3    m1.c 559.0994 571.7432 553.0994 13.89481
```

```
library(writexl)
#write_xlsx(df[order(df$AIC),c(1,3,2,4,5,6)],path="./df.xlsx")
```

Encara que veiem que millor AIC siguin els de mod0.1, m6.1 i després el nostre model escollit (molt semblant a mf.prob), veiem com els BIC del sdos primers son molt dolents respecte el nostres ja que encara que en tot moment ens hem guiat pel AIC, també hem aconseguit que dels models probats, el nostre sigui el que tingui un BIC més baix.


```
marginalModelPlot(mf)
```



```
marginalModelPlot(mf)
```


S'ajusta prou bé a les dades el model, encara que al final difereix una mica. Aquest desajust es provocat per la variable FEV, la forma de solucionar-ho seria afegint la variable FEV2, pero com no es veu molt greu mirarem abans capacitat predictiva.

```
plot(allEffects(mf))
```




On podem confirmar que hi ha interacció, com ja sospitavem a lo millor podriem treure visites_prev ja que es solapen les categories, després comprovem com el temps és lineal.

```
residualPlot(mf)
```



Veiem que no es pot acabar de validar ja que no tenim tendència central lineal. Mirem quina de les variables ho provoca (com hem anat veient és probable que sigui FEV)

```
residualPlots(mf)
```




```
##           Test stat Pr(>|Test stat|)
## FEV           1.7527         0.1855
## sexe
## temps         1.0196         0.3126
## visites_prev
```

Veiem pendent en la variable FEV. Com ja no podem introduir més canvis per millorar-ho, mirarem els outliers

Outliers i Punts influents

```
##-- Outliers i punts influents
plot(mf,5)
```



```
outlierTest(mf) #surt 1 outlier
```


```
## No Studentized residuals with Bonferroni p < 0.05
## Largest |rstudent|:
##      rstudent unadjusted p-value Bonferroni p
## 353 2.484342      0.012979      NA
```

```
outliers<-as.numeric(which(cooks.distance(mf)>4/500))
dades[outliers,c("sexe","FEV","edat","PAS","temps","n","y")]
```


```
##      sexe FEV edat PAS temps n y
## 3   home  74  45 124 1079 1 1
## 7   dona 109  91 131  954 1 1
## 40  dona 125  58 111  388 2 1
## 77  dona 110  46 159  731 1 1
## 79  dona 150  55 114 1780 0 0
## 115 home 140  61 101 1664 0 0
## 119 home  76  42 125 1165 1 1
## 126 home 149  28 115  624 0 0
## 149 dona  84  51 126  721 1 1
## 156 home  76  61  78  939 1 1
## 175 dona 148  70 110 1736 0 0
## 180 home  99  34 116 1492 1 1
## 263 home  64  31 118 1301 1 1
## 269 dona  72  49 134 1087 1 1
```

```
## 288 home 131 44 137 722 0 0
## 291 home 150 23 119 1295 0 0
## 292 home 145 33 129 919 0 0
## 296 dona 110 35 110 1372 2 1
## 298 dona 82 35 141 970 1 1
## 309 home 72 97 97 1511 1 1
## 320 dona 86 34 84 1701 2 1
## 328 home 74 34 135 1354 1 1
## 338 dona 149 30 140 1518 0 0
## 339 home 122 45 124 1808 0 0
## 350 dona 87 18 125 1694 2 1
## 353 dona 50 56 127 1383 1 1
## 382 home 119 91 131 1701 0 0
## 390 home 75 71 101 1515 2 1
## 414 home 133 51 112 1614 0 0
## 440 dona 137 48 141 870 1 1
## 451 dona 104 82 141 979 1 1
## 452 dona 108 18 96 424 1 1
## 473 home 76 52 112 1034 1 1
```

```
influenceIndexPlot(mf,label=row.names(dades),
  vars=c("Cook", "Student","hat"), id=list(n=5))
```



```
influencePlot(mf,label=row.names(dades), id=list(n=5))
```



##	StudRes	Hat	CookD
## 33	-1.244541	0.036245629	0.007310394
## 40	1.909276	0.022418092	0.018975111
## 115	-2.069385	0.021734178	0.026053124
## 126	-2.183268	0.013915153	0.021853043
## 175	-1.360851	0.039086176	0.010236149
## 263	2.211118	0.009336388	0.015847125
## 269	2.237202	0.008040463	0.014565861
## 270	-1.276835	0.036651851	0.007952644
## 291	-2.430424	0.008581013	0.024482516
## 353	2.484342	0.009718051	0.031291173
## 375	-1.122621	0.036522508	0.005560167
## 426	-1.251451	0.036325328	0.007442311

#cook 4/500

En 1er gràfic veiem com tenim residus de pearson elevats. Especialment hi han dos que passen del -4, 4. Mirant les observacions amb distància de cook elevades veiem com no hi ha ningú outlier produït per un error així que no els podem eliminar. Amb tots els gràfics veiem com tenim punts amb influència a priori i a posteriori i també residuos que estan mal explicats.


Canvi en les betes

```
par(mfrow=c(2,2))
dfb <- dfbetas(mf)
```


```

ndb1<-c()
for(i in 1:6){
  plot(abs(dfb[,i]),type='h',main=names(coef(mf))[i])
  abline(h=2/sqrt(500))
  ndb1<-c(ndb1,as.numeric(which(abs(dfb[,i])>2/sqrt(500))))
} #4/sqrt(n)=0.089


```



#Si ponemos limite en 2/sqrt(500) como en teoria vemos que afecta a los 4 coeficientes, pero si ponemos
`par(mfrow=c(2,2))`



```
dfb <- dfbetas(mf)
ndb2<-c()
for(i in 1:6){
  plot(abs(dfb[,i]),type='h',main=names(coef(mf))[i])
  abline(h=4/sqrt(500))
  ndb2<-c(ndb2,as.numeric(which(abs(dfb[,i])>4/sqrt(500))))
}
```



```
length(ndb1)
```

```
## [1] 214
```

```
length(ndb2)
```


```
## [1] 15
```

```
length(unique(ndb1))
```

```
## [1] 107
```

```
length(unique(ndb2))
```


```
## [1] 12
```



Aquí mirem la influència que té cada observació en cada coeficient. Si utilitzem el límit de la teoria veim que tenim per tots els coeficients varies observacions que els influencien. Utilitzan el límit vist al laboratori, el número d'observacions que influencien en els coeficients baixen: - Intercept → 3 - FEV → 4 - Temps → 0 I per l'interacció ninguna observació.

Dffits

```
p<-length(coef(mf))
plot(dffits(mf))
abline(h=2*sqrt(p/500))
abline(h=-2*sqrt(p/500))
```



```
sum(abs(dfbets(mf))>2*sqrt(p/500))
```

```
## [1] 31
```

Després d'evaluar com cada observació influeix en la seva pròpia predicció, veiem que si hi han algunes que ho fan.

Així que podem concloure que el model és robust i en general estable encara que haguem obtingut dfbets elevats perquè els coeficients no són altament sensibles per cap observació (dfbeta), per tant, encara que algunes observacions afectin a les seves prediccions, no ho fan per l'estimació dels coeficients de les betes. Encara que tenim valors atípics (residuos estandaritzats que passen del -4 o 4) no sembla que influeixin molt. I els que tenen una distància de Cook elevada ja hem comprovat que no són errors així que els deixem en el model.

Ara amb estadístic HM i el calibration.plot acabarem de validar model *Hosmer-Lemeshow*

```
seque <- c(0,seq(0.2,0.95,by=0.05))
dades$fitgrup <- cut(fitted(mf),breaks=seque)
(cfitgrup <- table(dades$y,dades$fitgrup))
```

```
##
##      (0,0.2] (0.2,0.25] (0.25,0.3] (0.3,0.35] (0.35,0.4] (0.4,0.45] (0.45,0.5]
## 0      189         23         27         18         10          9         10
## 1      22          9          7          4          8         10         18
##
```

```
##      (0.5,0.55] (0.55,0.6] (0.6,0.65] (0.65,0.7] (0.7,0.75] (0.75,0.8]
## 0           9           13           4           6           3           1
## 1          13          11           9           6          12           5
##
##      (0.8,0.85] (0.85,0.9] (0.9,0.95]
## 0           2           2           3
## 1          15           7          11
```

```
(csample <- tapply(dades$y,dades$fitgrup,sum))
```

```
##      (0,0.2] (0.2,0.25] (0.25,0.3] (0.3,0.35] (0.35,0.4] (0.4,0.45] (0.45,0.5]
##      22          9           7           4           8          10          18
## (0.5,0.55] (0.55,0.6] (0.6,0.65] (0.65,0.7] (0.7,0.75] (0.75,0.8] (0.8,0.85]
##      13          11           9           6          12           5          15
## (0.85,0.9] (0.9,0.95]
##       7          11
```

```
(cmodel <- tapply(fitted(mf),dades$fitgrup,sum))
```

```
##      (0,0.2] (0.2,0.25] (0.25,0.3] (0.3,0.35] (0.35,0.4] (0.4,0.45] (0.45,0.5]
## 23.629242  7.023988   9.247404   7.152441   6.760511   7.976443  13.282102
## (0.5,0.55] (0.55,0.6] (0.6,0.65] (0.65,0.7] (0.7,0.75] (0.75,0.8] (0.8,0.85]
## 11.565393 13.837886   8.217197   8.071140  10.938927   4.677088  14.010319
## (0.85,0.9] (0.9,0.95]
##  7.886676 12.896433
```

```
(XHL <- sum(((cmodel-csample)^2)/cmodel))
```

```
## [1] 6.959992
```


```
1-pchisq(XHL,length(seque)-1)
```

```
## [1] 0.9740245
```

Calibration plot

```
df <- data.frame(obs = factor(dades$y), # observat
                  pre = 1-fitted(mf)) # predict
calPlotData <- calibration(obs ~ pre, data = df)

plot(calPlotData)
```




El calibration.plot no sembla molt bo però afegirem els IC per veure si estan o no en la bisectriu

```
calPlotData <- calibration(obs ~ pre, data = df)

library(ggplot2)

ggplot(calPlotData, aes(x = midpoint, y = Percent / 100)) +
  geom_point(size = 3) +
  geom_errorbar(aes(ymin = Lower, ymax = Upper), width = 0.05) +
  geom_abline(slope = 1, intercept = 0, linetype = "dashed", color = "red") +
  labs(title = "Calibration Plot",
       x = "Predicted Probability",
       y = "Observed Proportion") +
  theme_minimal()
```




Veiem que tots els IC cauen dins la bisectriu, per tant, estadísticament les probabilitats predites i les observades son equivalents.

Comprovem que segons l'estadístic HM i el calibration.plot el model és bo

7. Capacitat predictiva


Anàlisi corba ROC

```
pr <- predict(mf,type="response")
y <- dades$y
boxplot(pr~y)
```



Les probabilitats predites pels que si han fet alguna visita son més altes

```
plot(roc(pr,factor(y)))
```





```
auc(roc(pr,factor(y)))
```

```
## [1] 0.823566
```

Tenim que el AUC es de 0.82 que és acceptable

```
# Corba ROC
dadesroc <- prediction(pr,y)
par(mfrow=c(1,2))
roc.perf <- performance(dadesroc,"auc",fpr.stop=0.05)
plot(performance(dadesroc,"err"))
plot(performance(dadesroc,"tpr","fpr"))
```



Veiem que el punt de tall òptim està al voltant de 0.4 per maximitzar la capacitat predictiva.

```
prob.visita <- mf$fit
visita.est <- ifelse(prob.visita<0.4,0,1)
(t <- table(visita.est,dades$y))
```

```
##
## visita.est  0   1
##           0 267  50
##           1  62 121
```

Proporció d'encerts

```
sum(diag(t))/sum(t)
```

```
## [1] 0.776
```

Sensibilitat

```
t[2,2]/sum(t[,2])
```

```
## [1] 0.7076023
```

Especificitat

```
t[1,1]/sum(t[,1])
```

```
## [1] 0.8115502
```

Valor predictiu positiu

```
t[2,2]/sum(t[2,])
```

```
## [1] 0.6612022
```

Valor predictiu negatiu

```
t[1,1]/sum(t[1,])
```

```
## [1] 0.8422713
```

```
# Model naive (prob. d anar votat si no sabem res)
m0 <- glm(y ~ 1, family=binomial, data=dades)
prob.visit <- m0$fit
visit.est <- ifelse(prob.visit<0.4,0,1)
t2 <- table(visit.est,dades$y)
t2[1,2]/sum(t2)
```

```
## [1] 0.342
```

Amb el model naive (si no sabem res) la proporció d'encerts passa de 75.8% del nostre model a un 34.2% *Pseudo-R*²

```
100*(1-mf$dev/mf$null.dev)
```

```
## [1] 25.01774
```

```
100*(1-(logLik(mf)/mf$df.residual)/(logLik(m0)/(m0$df.residual)))
```

```
## 'log Lik.' 24.25881 (df=6)
```

Tenim un pseudo-R2 baix: 0.25

8. Interpretació coeficients

```
mf
```

```
##
## Call: glm(formula = visita ~ FEV * sexe + temps + visites_prev, family = binomial(link = "logit"),
## data = dades)
##
## Coefficients:
## (Intercept) FEV sexehome temps visites_prevsi
## -6.519351 0.036982 -1.262019 0.000817 0.598828
## FEV:sexehome
## 0.022668
##
## Degrees of Freedom: 499 Total (i.e. Null); 494 Residual
## Null Deviance: 642.4
## Residual Deviance: 481.7 AIC: 493.7
```

$$\log\left(\frac{\pi}{1-\pi}\right) = \beta_0 + \beta_1 FEV + \beta_2 sexe_{home} + \beta_3 temps + \beta_4 visites_{prevsi} + \beta_{12} FEV : sexe_{home}$$

Hem de tenir en compte que els nivells de referència són dona i no en visites prèvies. Numèric

Com tenim funció link=logit el coeficient representa les logodds així que per poder extreure les odds em de fer exponencial

```
mf$coef[4]
```

```
## temps
## 0.0008169674
```

```
exp(mf$coef[4]) #com temps està en dies
```

```
## temps
## 1.000817
```

```
exp(30*mf$coef[4])
```

```
## temps
## 1.024812
```

```
exp(30*mf$coef[4])/(1+exp(30*mf$coef[4]))
```

```
## temps
## 0.5061269
```

Com les unitats de la variable temps són dies tenim que més dies de seguiment es relacionen amb una major probabilitat de que el pacient faci alguna visita. Un increment d'1 dia en els dies de seguiment suma 0.000817 als logodds i multiplica els odds per 1.000817, és a dir, incrementa els odds de fer una visita en un 0.0817%. Mirant-ho de manera mensual tenim que per un increment d'1 mes en el temps de seguiment s'incrementa les odds de fer una visita en 2.5%. Per tant, per cada mes que se està en estudi, es 1.025 cops més probable fer alguna visita respecte a no fer ninguna o *2.5% més probable fer alguna visita que no fer-la per cada increment d'1 mes en el temps d'estudi*

Catgòric

```
mf$coef[5]
```

```
## visites_prevsi  
##      0.5988282
```

```
exp(mf$coef[5])
```

```
## visites_prevsi  
##      1.819985
```

```
exp(mf$coef[5])/(1+exp(mf$coef[5]))
```

```
## visites_prevsi  
##      0.6453882
```

Els que si han tingut una visita prèvia abans de l'estudi, sels hi suma 0.599 als logodds respecte als que no tenen i multiplica els odds per 1.82, és a dir, els que han tingut una visita prèvia tenen 1.82 cops més probabilitats de fer alguna visita que els que no. *82% més probable fer alguna visita respecte a no fer-la quan s'ha fet una visita prèvia*

```
#####RECOMEN  
# Recomptes
```

Modelització

Com que la variable resposta és el nombre de visites realitzades en el temps de seguiment i aquest temps és diferent per a cada pacient, necessitem l'**offset** (taxa de nombre de visites per temps de seguiment). Així doncs, incloem `offset(log(temps))` al model com a predictora.

Amb l'anàlisi descriptiva i el model ajustat a resposta binària sabem que com a mínim les variables sexe, temps, PAS i FEV s'hauran d'incloure en el model. I també tindrem l'interacció sexe:FEV ### Selecció de variables

Primer fem la selecció de variables per un model poisson.

```
mod.r0 <- glm(n ~ sexe + visites_prev + FEV + edat + PAS + offset(log(temps)) +  
             sexe:visites_prev + sexe:FEV + sexe:edat + sexe:PAS + sexe:temps +  
             visites_prev:FEV + visites_prev:edat + visites_prev:PAS +  
             visites_prev:temps, family = poisson, dades)
```

```
mod.r1 <- step(mod.r0, direction="both", k=2, trace=FALSE) #fem segons criteri AIC ja que busquem predi  
mod.r2 <- step(mod.r0, direction="both", k=log(nrow(dades)), trace=FALSE)  
Anova(mod.r1)
```

```
## Analysis of Deviance Table (Type II tests)
```

```
##
```

```
## Response: n
```

```
##              LR Chisq Df Pr(>Chisq)  
## sexe              146.50  1 < 2.2e-16 ***  
## visites_prev       36.58  1  1.467e-09 ***  
## FEV                773.80  1 < 2.2e-16 ***
```

```
## edat          30.50  1  3.342e-08 ***
## PAS          39.10  1  4.030e-10 ***
## sexe:visites_prev  5.62  1   0.01775 *
## sexe:FEV        4.36  1   0.03678 *
## sexe:edat       2.10  1   0.14684
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Anova(mod.r2)
```

```
## Analysis of Deviance Table (Type II tests)
##
## Response: n
##          LR Chisq Df Pr(>Chisq)
## sexe      146.50  1 < 2.2e-16 ***
## visites_prev 39.37  1 3.515e-10 ***
## FEV       784.54  1 < 2.2e-16 ***
## edat       28.37  1 1.003e-07 ***
## PAS       40.21  1 2.279e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Agafarem model AIC on tenim resultat esperable a més que s'han afegit les interaccions de sexe amb edat i visites_prev (aquesta última no significativa) i de manera aditiva edat i visites_prev.

Poisson

Ajustem les dades a un model poisson. I com veiem que interacció sexe:edat no significativa ajustarem també model sense aquesta interacció.

```
mod.poisson0 <- glm(n ~ sexe + visites_prev + FEV + edat + PAS + sexe:FEV+sexe:edat+sexe:visites_prev+
                    offset(log(temps)), family = poisson, dades)
Anova(mod.poisson0)
```

```
## Analysis of Deviance Table (Type II tests)
##
## Response: n
##          LR Chisq Df Pr(>Chisq)
## sexe      146.50  1 < 2.2e-16 ***
## visites_prev 36.58  1 1.467e-09 ***
## FEV       773.80  1 < 2.2e-16 ***
## edat       30.50  1 3.342e-08 ***
## PAS       39.10  1 4.030e-10 ***
## sexe:FEV    4.36  1   0.03678 *
## sexe:edat   2.10  1   0.14684
## sexe:visites_prev 5.62  1   0.01775 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
mod.poisson1 <- glm(n ~ sexe + visites_prev + FEV + edat + PAS + sexe:FEV+sexe:visites_prev+
                    offset(log(temps)), family = poisson, dades)
AIC(mod.poisson0)
```

```
## [1] 1122.61
```

```
AIC(mod.poisson1)
```

```
## [1] 1122.715
```

```
BIC(mod.poisson0)
```

```
## [1] 1160.541
```

```
BIC(mod.poisson1)
```

```
## [1] 1156.432
```

Com interacció surt no significativa i a més AIC son molt semblant però BIC millora si treiem interacció així que ens quedem amb model sense interacció

```
library(AER)
```

```
## Cargando paquete requerido: sandwich
```

```
## Cargando paquete requerido: survival
```

```
## Warning: package 'survival' was built under R version 4.4.3
```

```
##
```

```
## Adjuntando el paquete: 'survival'
```

```
## The following object is masked from 'package:caret':
```

```
##
```

```
## cluster
```

```
dispersiontest(mod.poisson1, trafo = 1) #  $V(Y) = (1+\alpha)*\mu$  --> Y Quasi Poisson
```

```
##
```

```
## Overdispersion test
```

```
##
```

```
## data: mod.poisson1
```

```
## z = 5.1854, p-value = 1.078e-07
```

```
## alternative hypothesis: true alpha is greater than 0
```

```
## sample estimates:
```

```
## alpha
```

```
## 0.4172878
```

```
dispersiontest(mod.poisson1, trafo = 2) #  $V(Y) = \mu + \alpha*\mu^2$  --> Y Bin Neg
```

```
##
## Overdispersion test
##
## data: mod.poisson1
## z = 4.8318, p-value = 6.766e-07
## alternative hypothesis: true alpha is greater than 0
## sample estimates:
##      alpha
## 0.1490144
```

Amb `trafo=1` fem el test per la relació lineal i amb `trafo=2` per la relació quadràtica. Veiem que el model té dispersió. Com que ambdós p-valors són menors que 0.05, provarem d'ajustar les dades amb un model binomial negatiu, ja que és més flexible que el quasi-poisson.

Binomial negativa

```
library(MASS)
mod.nb0 <- glm.nb(n ~ sexe + visites_prev + FEV + edat + PAS + sexe:FEV+sexe:visites_prev+
                  offset(log(temps)), dades)
summary(mod.poisson1)
```

```
##
## Call:
## glm(formula = n ~ sexe + visites_prev + FEV + edat + PAS + sexe:FEV +
##      sexe:visites_prev + offset(log(temps)), family = poisson,
##      data = dades)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -11.326051    0.650045  -17.423  < 2e-16 ***
## sexehome        -0.674778    0.674188   -1.001   0.3169
## visites_prevsi    0.386187    0.218199    1.770   0.0767 .
## FEV              0.042142    0.003876   10.872  < 2e-16 ***
## edat             0.011737    0.002122    5.530 3.19e-08 ***
## PAS             -0.017372    0.002718   -6.390 1.66e-10 ***
## sexehome:FEV      0.008840    0.004562    1.938   0.0527 .
## sexehome:visites_prevsi 0.679770    0.295261    2.302   0.0213 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for poisson family taken to be 1)
##
##      Null deviance: 1673.81  on 499  degrees of freedom
## Residual deviance:  634.71  on 492  degrees of freedom
## AIC: 1122.7
##
## Number of Fisher Scoring iterations: 6
```

```
summary(mod.nb0)
```

```
##
```

```
## Call:
## glm.nb(formula = n ~ sexe + visites_prev + FEV + edat + PAS +
##       sexe:FEV + sexe:visites_prev + offset(log(temps)), data = dades,
##       init.theta = 1.551153759, link = log)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -11.627039   0.880591 -13.204 < 2e-16 ***
## sexehome       -0.806361   0.889584  -0.906  0.36470
## visites_prevsi  0.265576   0.289351   0.918  0.35871
## FEV             0.043611   0.004910   8.881 < 2e-16 ***
## edat           0.009575   0.003500   2.735  0.00623 **
## PAS            -0.014502   0.004548  -3.189  0.00143 **
## sexehome:FEV    0.009156   0.006243   1.467  0.14247
## sexehome:visites_prevsi 0.828753   0.413261   2.005  0.04492 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Negative Binomial(1.5512) family taken to be 1)
##
## Null deviance: 896.23 on 499 degrees of freedom
## Residual deviance: 386.36 on 492 degrees of freedom
## AIC: 1054.5
##
## Number of Fisher Scoring iterations: 1
##
##              Theta:  1.551
##             Std. Err.:  0.333
##
## 2 x log-likelihood: -1036.504
```

```
Anova(mod.nb0)
```

```
## Analysis of Deviance Table (Type II tests)
##
## Response: n
##              LR Chisq Df Pr(>Chisq)
## sexe          51.59  1 6.822e-13 ***
## visites_prev  11.27  1 0.0007887 ***
## FEV          367.11  1 < 2.2e-16 ***
## edat           7.48  1 0.0062343 **
## PAS          10.35  1 0.0012978 **
## sexe:FEV       2.04  1 0.1531563
## sexe:visites_prev 3.99  1 0.0458135 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Els coeficients son semblants a la Poisson però els errors estandards són superiors en el cas de la binomial negativa. Com ara surt interacció no significativa, treurem l'interacció sexe:FEV

```
mod.nb1 <- glm.nb(n ~ sexe + visites_prev + FEV + edat + PAS +sexe:visites_prev+
                  offset(log(temps)), dades)
Anova(mod.nb1)
```

```
## Analysis of Deviance Table (Type II tests)
##
## Response: n
##               LR Chisq Df Pr(>Chisq)
## sexe           51.36  1  7.681e-13 ***
## visites_prev   11.61  1  0.000656 ***
## FEV            365.80  1  < 2.2e-16 ***
## edat           7.23  1  0.007169 **
## PAS            10.43  1  0.001241 **
## sexe:visites_prev 3.48  1  0.062047 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Avaluem la bondat de l'ajust amb l'estadístic de Pearson.

```
(X2P <- sum(resid(mod.nb1,type="pearson")^2))
```

```
## [1] 446.7556
```

```
1 - pchisq(X2P,mod.nb0$df.residual)
```

```
## [1] 0.9289022
```

Segons l'estadístic, el model és vàlid.

Validació

```
residualPlot(mod.nb1, layout=c(2,2))
```

```
## Warning in plot.window(...): "layout" es un parámetro gráfico inválido
```

```
## Warning in plot.xy(xy, type, ...): "layout" es un parámetro gráfico inválido
```


```
## Warning in axis(side = side, at = at, labels = labels, ...): "layout" es un
## parámetro gráfico inválido
```

```
## Warning in axis(side = side, at = at, labels = labels, ...): "layout" es un
## parámetro gráfico inválido
```

```
## Warning in box(...): "layout" es un parámetro gráfico inválido
```

```
## Warning in title(...): "layout" es un parámetro gráfico inválido
```

```
## Warning in plot.xy(xy.coords(x, y), type = type, ...): "layout" es un parámetro
## gráfico inválido
```



```
residualPlot(mod.nb0, layout=c(2,2))
```

```
## Warning in plot.window(...): "layout" es un parámetro gráfico inválido
```

```
## Warning in plot.xy(xy, type, ...): "layout" es un parámetro gráfico inválido
```


```
## Warning in axis(side = side, at = at, labels = labels, ...): "layout" es un  
## parámetro gráfico inválido
```

```
## Warning in axis(side = side, at = at, labels = labels, ...): "layout" es un  
## parámetro gráfico inválido
```

```
## Warning in box(...): "layout" es un parámetro gráfico inválido
```

```
## Warning in title(...): "layout" es un parámetro gráfico inválido
```

```
## Warning in plot.xy(xy.coords(x, y), type = type, ...): "layout" es un parámetro  
## gráfico inválido
```



```
library(pscl)
```

```
## Classes and Methods for R originally developed in the
## Political Science Computational Laboratory
## Department of Political Science
## Stanford University (2002-2015),
## by and under the direction of Simon Jackman.
## hurdle and zeroinfl functions by Achim Zeileis.
```

```
# Ajustar un modelo Zero-Inflated Poisson
#modelo_zip <- zeroinfl(n ~ sexe + visites_prev + FEV + edat + PAS + sexe:FEV+sexe:visites_prev+
#
offset(log(temps)) | 1, data = dades)
#summary(modelo_zip)
```

```
# Ajustar un modelo Zero-Inflated Negative Binomial
#modelo_zinb <- zeroinfl(n ~ sexe + visites_prev + FEV + edat + PAS + sexe:FEV+sexe:visites_prev+
#
offset(log(temps)) | 1, dist = "negbin", data = dades)
```

```
library(glmmTMB)
```

```
mzip <- glmmTMB(n ~ sexe + visites_prev + FEV + edat + PAS + sexe:FEV+sexe:visites_prev+
  offset(log(temps)),data=dades,
  zi=~sexe,family=poisson)
mzinb <- glmmTMB(n ~ sexe + visites_prev + FEV + edat + PAS + sexe:FEV+sexe:visites_prev+
  offset(log(temps)),data=dades,
```

```
zi=~sexe ,family=nbinom2)
```

```
AIC(mzip)
```

```
## [1] 1012.867
```

```
AIC(mzinb)
```

```
## [1] 1014.847
```

```
AIC(mod.poisson1)
```

```
## [1] 1122.715
```

```
AIC(mod.nb0)
```

```
## [1] 1054.504
```

```
AIC(mod.nb1)
```

```
## [1] 1054.543
```

```
print("*****")
```

```
## [1] "*****"
```

```
BIC(mzip)
```

```
## [1] 1055.013
```

```
BIC(mzinb)
```

```
## [1] 1061.208
```

```
BIC(mod.poisson1)
```

```
## [1] 1156.432
```

```
BIC(mod.nb0)
```

```
## [1] 1092.436
```

```
BIC(mod.nb1)
```

```
## [1] 1088.26
```

Millor zip de tots els models

```

tabla_observada <- table(dades$n == 0)

# Predicción de ceros bajo Poisson
predicciones <- predict(mod.poisson1, type = "response")
ceros_esperados <- sum(dpois(0, lambda = predicciones))
#sum(dnbinom(0, size = mod.nb1$theta, mu = predicciones))

# Comparar
print(tabla_observada)

##
## FALSE TRUE
## 171 329

print(ceros_esperados)

## [1] 295.2081

#Nomes per comprobar si necessari model zero inflat
modelo_zip <- zeroinfl(n ~ sexe + visites_prev + FEV + edat + PAS + sexe:FEV+sexe:visites_prev+
                      offset(log(temps)) | sexe, data = dades)
vuong(mod.poisson1,modelo_zip)

## Vuong Non-Nested Hypothesis Test-Statistic:
## (test-statistic is asymptotically distributed N(0,1) under the
## null that the models are indistinguishable)
## -----
##              Vuong z-statistic              H_A      p-value
## Raw              -3.969593 model2 > model1 3.5998e-05
## AIC-corrected    -3.830123 model2 > model1 6.4040e-05
## BIC-corrected    -3.536215 model2 > model1 0.00020295

#vuong(mod.nb1, modelo_zinb) #sla emejor modelo zinflado
#vuong(mod.nb1,modelo_zip)

#Anova(modelo_zinb,component="cond")
#Anova(modelo_zinb2,component="zi")
#modelo_zinb2 <- zeroinfl(n ~ sexe + FEV + edat + PAS + sexe:FEV+
#                          offset(log(temps)) | sexe +visites_prev +FEV + edat + PAS + #sexe:FEV+sexe:visites_prev+
#                          offset(log(temps)), dist = "negbin", data = dades)
#Anova(modelo_zinb2,component="cond")

```

Mejor zero inflado

Selecció de variables

```

mzip1 <- glmmTMB(n ~ sexe + visites_prev + FEV + edat + PAS +sexe:visites_prev+
                 offset(log(temps)),data=dades,
                 zi=~sexe,family=poisson)
Anova(mzip1,component="cond")

```

```
## Analysis of Deviance Table (Type II Wald chisquare tests)
##
## Response: n
##           Chisq Df Pr(>Chisq)
## sexe      44.853  1  2.123e-11 ***
## visites_prev 18.987  1  1.316e-05 ***
## FEV      431.129  1  < 2.2e-16 ***
## edat      14.368  1  0.0001503 ***
## PAS       43.185  1  4.980e-11 ***
## sexe:visites_prev 5.047  1  0.0246685 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Anova(mzip1,component="zi")
```

```
## Analysis of Deviance Table (Type II Wald chisquare tests)
##
## Response: n
##           Chisq Df Pr(>Chisq)
## sexe 7.1883  1  0.007338 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
#residualPlot(mzip1)
```

Tot és significatiu.

```
#afegim variables
mzip1.1 <- glmmTMB(n ~ sexe + visites_prev + FEV + edat + PAS +sexe:visites_prev+
                  offset(log(temps)),data=dades,
                  zi=~sexe + visites_prev,family=poisson)
Anova(mzip1.1,component="cond")
```

```
## Analysis of Deviance Table (Type II Wald chisquare tests)
##
## Response: n
##           Chisq Df Pr(>Chisq)
## sexe      44.0721  1  3.165e-11 ***
## visites_prev 18.4525  1  1.742e-05 ***
## FEV      430.2208  1  < 2.2e-16 ***
## edat      14.3009  1  0.0001558 ***
## PAS       43.1577  1  5.050e-11 ***
## sexe:visites_prev 4.9385  1  0.0262655 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Anova(mzip1.1,component="zi")
```

```
## Analysis of Deviance Table (Type II Wald chisquare tests)
##
## Response: n
```

```
##               Chisq Df Pr(>Chisq)
## sexe          7.1361  1   0.007555 **
## visites_prev  0.0259  1   0.872184
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- visites_prev no significativa

```
#afegim variables
mzip1.2 <- glmmTMB(n ~ sexe + visites_prev + FEV + edat + PAS +sexe:visites_prev+
                  offset(log(temps)),data=dades,
                  zi=~sexe + edat,family=poisson)
Anova(mzip1.2,component="cond")
```

```
## Analysis of Deviance Table (Type II Wald chisquare tests)
##
## Response: n
##               Chisq Df Pr(>Chisq)
## sexe          43.6340  1  3.959e-11 ***
## visites_prev   19.2703  1  1.135e-05 ***
## FEV            430.0086  1 < 2.2e-16 ***
## edat           11.2121  1  0.0008127 ***
## PAS            42.4360  1  7.303e-11 ***
## sexe:visites_prev  5.1434  1  0.0233348 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Anova(mzip1.2,component="zi")
```

```
## Analysis of Deviance Table (Type II Wald chisquare tests)
##
## Response: n
##               Chisq Df Pr(>Chisq)
## sexe 7.5097  1   0.006137 **
## edat 0.5534  1   0.456940
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- edat no significativa

```
#afegim variables
mzip1.3 <- glmmTMB(n ~ sexe + visites_prev + FEV + edat + PAS +sexe:visites_prev+
                  offset(log(temps)),data=dades,
                  zi=~sexe + sexe:visites_prev,family=poisson)
Anova(mzip1.3,component="cond")
```

```
## Analysis of Deviance Table (Type II Wald chisquare tests)
##
## Response: n
##               Chisq Df Pr(>Chisq)
## sexe          44.0223  1  3.247e-11 ***
```

```
## visites_prev      17.9311  1  2.291e-05 ***
## FEV               430.0253  1  < 2.2e-16 ***
## edat              14.3010  1  0.0001558 ***
## PAS               43.1580  1  5.049e-11 ***
## sexe:visites_prev  4.5409  1  0.0330944 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Anova(mzip1.3,component="zi")
```

```
## Analysis of Deviance Table (Type II Wald chisquare tests)
##
## Response: n
##              Chisq Df Pr(>Chisq)
## sexe          7.2159  1  0.007226 **
## sexe:visites_prev 0.0296  2  0.985327
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- interacció sexe:visites_fev tampoc és significativa

```
mzip2 <- zeroinfl(n ~ sexe + visites_prev + FEV + edat + PAS + sexe:FEV+sexe:visites_prev+
                  offset(log(temps)) | sexe, data=dades)
AIC(mzip2)
```

```
## [1] 1012.867
```

```
BIC(mzip2)
```

```
## [1] 1055.013
```

```
mzip2.1 <- zeroinfl(n ~ sexe + visites_prev + FEV + edat + PAS + sexe:FEV+sexe:visites_prev+
                    offset(log(temps)) | sexe + FEV, data=dades)
AIC(mzip2.1)
```

```
## [1] 1013.168
```

```
BIC(mzip2.1)
```

```
## [1] 1059.529
```

- AIC i BIC més grans

```
mzip2.2 <- zeroinfl(n ~ sexe + visites_prev + FEV + edat + PAS + sexe:FEV+sexe:visites_prev+
                    offset(log(temps)) | sexe + PAS, data=dades)
AIC(mzip2.2)
```


```
## [1] 1012.703
```

```
BIC(mzip2.2)
```


```
## [1] 1059.064
```

Capacitat predictiva

```
pr <- predict(mzip1,type='response')/dades$temps  
obs<-dades$n/dades$temps  
pr2<-predict(mod.nb1,type='response')/dades$temps  
par(mfrow=c(1,2))  
plot(pr,obs,main="Escala additiva",xlab='Predit',ylab='Observat');abline(0,1,col=2)  
plot(pr+0.1,obs+0.1,log='xy',main="Escala multiplicativa",xlab='Predit',ylab='Observat');abline(0,1,col=2)
```



```
plot(pr2,obs,main="Escala additiva",xlab='Predit',ylab='Observat');abline(0,1,col=2)  
plot(pr2+0.1,obs+0.1,log='xy',main="Escala multiplicativa",xlab='Predit',ylab='Observat');abline(0,1,col=2)
```



Complicar el model.

```
mzip2 <- glmmTMB(n ~ sexe*FEV+temps+visites_prev+offset(log(temps)),data=dades,
                  zi=~sexe
                  ,family=poisson)
Anova(mzip2,component="cond")
```

```
## Analysis of Deviance Table (Type II Wald chisquare tests)
##
## Response: n
##           Chisq Df Pr(>Chisq)
## sexe       44.0855  1  3.143e-11 ***
## FEV       441.3521  1 < 2.2e-16 ***
## temps      0.1301  1   0.7184
## visites_prev 27.9860  1 1.222e-07 ***
## sexe:FEV    0.1172  1   0.7321
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Anova(mzip2,component="zi")
```

```
## Analysis of Deviance Table (Type II Wald chisquare tests)
##
## Response: n
##           Chisq Df Pr(>Chisq)
```

```
## sexe 8.0618 1 0.004521 **
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
mzip3 <- glmTMB(n ~ sexe+FEV+temps+visites_prev+offset(log(temps)),data=dades,
               zi=~sexe
               ,family=poisson)
Anova(mzip3,component="cond")
```

```
## Analysis of Deviance Table (Type II Wald chisquare tests)
##
## Response: n
##           Chisq Df Pr(>Chisq)
## sexe       44.2768 1 2.851e-11 ***
## FEV       441.1068 1 < 2.2e-16 ***
## temps       0.1448 1 0.7035
## visites_prev 28.0340 1 1.192e-07 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
#Anova(mzip,component="zi")
```

```
mzip4 <- glmTMB(n ~ sexe+FEV+visites_prev+PAS+offset(log(temps)),data=dades,
               zi=~sexe
               ,family=poisson)
Anova(mzip4,component="cond")
```

```
## Analysis of Deviance Table (Type II Wald chisquare tests)
##
## Response: n
##           Chisq Df Pr(>Chisq)
## sexe       44.707 1 2.289e-11 ***
## FEV       461.957 1 < 2.2e-16 ***
## visites_prev 24.445 1 7.646e-07 ***
## PAS        39.516 1 3.253e-10 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Anova(mzip4,component="zi")
```

```
## Analysis of Deviance Table (Type II Wald chisquare tests)
##
## Response: n
##           Chisq Df Pr(>Chisq)
## sexe 8.7493 1 0.003097 **
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
mzip5 <- glmTMB(n ~ sexe+FEV+visites_prev+edat+PAS+offset(log(temps)),data=dades,
               zi=~sexe +offset(log(temps))
               ,family=poisson)
Anova(mzip5,component="cond")
```

```
## Analysis of Deviance Table (Type II Wald chisquare tests)
##
## Response: n
##           Chisq Df Pr(>Chisq)
## sexe      49.150  1  2.371e-12 ***
## FEV       436.272  1  < 2.2e-16 ***
## visites_prev 21.353  1  3.821e-06 ***
## edat      14.685  1  0.0001271 ***
## PAS       44.355  1  2.738e-11 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Anova(mzip5,component="zi")
```

```
## Analysis of Deviance Table (Type II Wald chisquare tests)
##
## Response: n
##           Chisq Df Pr(>Chisq)
## sexe  5.9186  1    0.01498 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
mzip6 <- glmmTMB(n ~ sexe*edat+FEV+visites_prev+PAS+offset(log(temps)),data=dades,
                 zi=~sexe +offset(log(temps))
                 ,family=poisson)
Anova(mzip6,component="cond")
```

```
## Analysis of Deviance Table (Type II Wald chisquare tests)
##
## Response: n
##           Chisq Df Pr(>Chisq)
## sexe      48.7573  1  2.897e-12 ***
## edat      14.7187  1  0.0001248 ***
## FEV       436.9327  1  < 2.2e-16 ***
## visites_prev 21.0752  1  4.416e-06 ***
## PAS       43.9626  1  3.347e-11 ***
## sexe:edat   1.1905  1  0.2752263
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Anova(mzip6,component="zi")
```

```
## Analysis of Deviance Table (Type II Wald chisquare tests)
##
## Response: n
##           Chisq Df Pr(>Chisq)
## sexe  5.1103  1    0.02378 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
mzip7 <- glmmTMB(n ~ sexe*PAS+edat+FEV+visites_prev+offset(log(temps)),data=dades,
                 zi=~sexe +offset(log(temps))
                 ,family=poisson)
Anova(mzip7,component="cond")
```

```
## Analysis of Deviance Table (Type II Wald chisquare tests)
##
## Response: n
##           Chisq Df Pr(>Chisq)
## sexe       47.6733  1  5.035e-12 ***
## PAS        45.2026  1  1.777e-11 ***
## edat       14.8194  1  0.0001183 ***
## FEV       440.2886  1  < 2.2e-16 ***
## visites_prev 21.2973  1  3.933e-06 ***
## sexe:PAS     4.0375  1  0.0444987 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Anova(mzip7,component="zi")
```

```
## Analysis of Deviance Table (Type II Wald chisquare tests)
##
## Response: n
##           Chisq Df Pr(>Chisq)
## sexe 6.5383  1  0.01056 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
mzip8 <- glmmTMB(n ~ sexe*PAS+edat+FEV*visites_prev+offset(log(temps)),data=dades,
                 zi=~sexe +offset(log(temps))
                 ,family=poisson)
Anova(mzip8,component="cond")
```

```
## Analysis of Deviance Table (Type II Wald chisquare tests)
##
## Response: n
##           Chisq Df Pr(>Chisq)
## sexe       47.6676  1  5.050e-12 ***
## PAS        45.1913  1  1.787e-11 ***
## edat       14.7905  1  0.0001201 ***
## FEV       440.2326  1  < 2.2e-16 ***
## visites_prev 21.3061  1  3.915e-06 ***
## sexe:PAS     4.0436  1  0.0443386 *
## FEV:visites_prev 0.0051  1  0.9428967
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Anova(mzip8,component="zi")
```

```
## Analysis of Deviance Table (Type II Wald chisquare tests)
##
```

```
## Response: n
##      Chisq Df Pr(>Chisq)
## sexe 6.546  1    0.01051 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
mzip9 <- glmmTMB(n ~ sexe*PAS+FEV+edat+visites_prev+offset(log(temps)),data=dades,
                 zi=~sexe +offset(log(temps))
                 ,family=poisson)
Anova(mzip9,component="cond")
```

```
## Analysis of Deviance Table (Type II Wald chisquare tests)
##
## Response: n
##      Chisq Df Pr(>Chisq)
## sexe      47.5929  1 5.246e-12 ***
## PAS       44.6930  1 2.305e-11 ***
## FEV      440.1226  1 < 2.2e-16 ***
## edat      14.9018  1 0.0001133 ***
## visites_prev 20.7549  1 5.220e-06 ***
## sexe:PAS      3.9977  1 0.0455620 *
## edat:visites_prev 1.0658  1 0.3018996
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Anova(mzip9,component="zi")
```

```
## Analysis of Deviance Table (Type II Wald chisquare tests)
##
## Response: n
##      Chisq Df Pr(>Chisq)
## sexe 6.391  1    0.01147 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
mzipdf<-mzip7
```

No convergeix perquè és massa complex. De moment millor model zip mzipdf

```
mzip10 <- glmmTMB(n ~ sexe*PAS+FEV+edat+visites_prev+offset(log(temps)),data=dades,
                  zi=~sexe+PAS +offset(log(temps))
                  ,family=poisson)
```

Interpretació

```
library("multcomp")
```

```
## Cargando paquete requerido: mvtnorm
```

```
## Cargando paquete requerido: TH.data
```

```
##
```

```
## Adjuntando el paquete: 'TH.data'
```

```
## The following object is masked from 'package:MASS':
```

```
##
```

```
##      geyser
```

```
library(emmeans)
```

```
## Welcome to emmeans.
```

```
## Caution: You lose important information if you filter this package's results.
```

```
## See '? untidy'
```

```
cld(emmeans(mzip1, ~FEV|sexe,type="response"))
```

```
## sexe = dona:
```

```
## FEV rate SE df asymp.LCL asymp.UCL .group
```

```
## 101 0.388 0.0550 Inf 0.294 0.512 1
```

```
##
```

```
## sexe = home:
```

```
## FEV rate SE df asymp.LCL asymp.UCL .group
```

```
## 101 0.620 0.0785 Inf 0.484 0.795 1
```

```
##
```

```
## Results are averaged over the levels of: visites_prev
```

```
## Confidence level used: 0.95
```

```
## Intervals are back-transformed from the log scale
```

```
## Note: contrasts are still on the log scale. Consider using
```

```
##      regrid() if you want contrasts of back-transformed estimates.
```

```
## significance level used: alpha = 0.05
```

```
## NOTE: If two or more means share the same grouping symbol,
```

```
##      then we cannot show them to be different.
```

```
##      But we also did not show them to be the same.
```

```
EQM
```

```
EQM <- sum((pr-dades$n)^2)/length(pr) # Error quadratic mitja  
sqrt(EQM)
```

```
## [1] 3.072175
```

```
sd(dades$n)
```

```
## [1] 2.849322
```


```
pr <- predict(mod.nb1,type='response')
```

```
par(mfrow=c(1,2))
```


```
plot(pr,dades$n,main="Escala aditiva",xlab='Predit',ylab='Observat');abline(0,1,col=2)
```

```
plot(pr+0.1,dades$n+0.1,log='xy',main="Escala multiplicativa",xlab='Predit',ylab='Observat');abline(0,1)
```

Escala aditiva



Escala multiplicativa



```
mod.nb1 <- glm.nb(n ~ sexe + visites_prev + FEV + edat + PAS +sexe:visites_prev+
                  offset(log(temps)), dades)
pr <- predict(mzip1,type='response')/dades$temps
obs<-dades$n/dades$temps
pr2<-predict(mod.nb1,type='response')/dades$temps
sum((pr-obs)^2)/length(pr)
```

```
## [1] 2.106364e-06
```

```
sum((pr2-obs)^2)/length(pr)
```

```
## [1] 2.100138e-06
```

```
sum((pr2-pr)^2)/length(pr)
```

```
## [1] 2.406621e-08
```

```
mod.poissonnulo <- glm(n ~ 1, family = poisson, dades)
mod.nbnul<-glm.nb(n ~ 1, dades)
mod.zipn<-glmmTMB(n ~ 1,data=dades,
                  zi=~sexe
                  ,family=poisson)
mod.zibn<-glmmTMB(n ~ 1,data=dades,
```

```
      zi=~1
      ,family=nbinom2)
deviance(mod.poissonnulo)
```

```
## [1] 1749.621
```

```
deviance(mod.nbnul)
```

```
## [1] 361.6814
```

```
deviance(mod.zipn)
```

```
## [1] 1647.211
```

```
deviance(mod.zibn)
```

```
## [1] 361.6814
```